Программа профессиональной переподготовки
«Разработка нейросетей на Python с нуля до проекта (вторая ступень)»

# ИТОГОВАЯ АТТЕСТАЦИОННАЯ РАБОТА

**Тема:**

**«Автоматическая классификация типов документов клиентов банка с использованием свёрточных нейронных сетей и переноса обучения»**

**Выполнили:**
Зангиев Мовсар Абдул-Саламович
Зангиева Медина Абдул-Саламовна
Зангиев Муслим Абдул-Саламович

**Руководитель:** Кузьмин Дмитрий

2026 г.

# Содержание

СОДЕРЖАНИЕ

Введение……3
1. Обзорная часть……..4
1.1. Постановка задачи классификации документов…….4
1.2. Обзор инструментов и архитектур нейронных сетей……..5
2. Проектирование приложения……...6
2.1. Описание данных — датасет MIDV-500……6
2.2. Функциональные требования…….7
2.3. Нефункциональные требования……..7
2.4. Стадии разработки……7
2.5. Архитектура решения…….8
3. Реализация приложения……9
3.1. Разведочный анализ данных (EDA)……9
3.2. Подготовка данных и разделение на выборки……11
3.3. Обоснование выбора моделей для сравнения……12
3.4. Модель 1. Свёрточная сеть с нуля (baseline)……13
3.5. Модель 2. MobileNetV2 с переносом обучения……14
3.6. Модель 3. ResNet50 с переносом обучения……...15
3.7. Результаты обучения и сравнение моделей……16
3.8. Анализ ошибок (Confusion Matrix)……18
3.9. Тестирование на картинке из интернета……19
Заключение…….20
Список использованных источников……...22

# Введение

**Актуальность темы.** Банковская отрасль переживает масштабную цифровую трансформацию. По данным Центрального банка Российской Федерации, доля удалённых операций в розничном обслуживании за период 2020–2025 гг. выросла в несколько раз. В условиях санкционных ограничений и ухода с рынка ряда иностранных банков отечественные кредитные организации, в том числе АО «Россельхозбанк» (РСХБ), активно развивают обслуживание нерезидентов — иностранных работников сельскохозяйственного сектора, мигрантов, иностранных инвесторов агропромышленного комплекса. При открытии счетов, выдаче кредитов и проведении операций такие клиенты предъявляют документы, удостоверяющие личность, разных государств — паспорта, идентификационные карточки, водительские удостоверения. Оператор банка вынужден вручную определить тип документа и направить его по правильному маршруту обработки в рамках процедуры KYC (Know Your Customer — «знай своего клиента»), установленной Федеральным законом от 07.08.2001 №115-ФЗ «О противодействии легализации (отмыванию) доходов, полученных преступным путём, и финансированию терроризма».

Ручная классификация документов требует 20–30 секунд рабочего времени оператора на каждый экземпляр и подвержена человеческому фактору. При потоке 10 000 документов в день это составляет порядка 70–80 человеко-часов работы ежедневно. Автоматизация этого процесса методами компьютерного зрения (Computer Vision) и глубокого обучения (Deep Learning) представляет собой актуальную задачу, решение которой может принести существенный экономический эффект.

**Цель работы** — разработать и сравнить три модели классификации типов документов, удостоверяющих личность, выбрать оптимальную архитектуру для внедрения в АО «Россельхозбанк» и продемонстрировать её работу.

**Задачи работы:**

— провести анализ доступных датасетов документов и выбрать подходящий;

— выполнить разведочный анализ данных (EDA) для понимания структуры выборки;

— реализовать и обучить три свёрточные нейронные сети разной сложности — базовую CNN с нуля, MobileNetV2 и ResNet50 с переносом обучения;

— провести сравнительный анализ моделей по метрикам точности (Accuracy, F1-score), размеру и времени инференса (предсказания);

— протестировать лучшую модель на реальной картинке документа, скачанной из открытого интернета;
— сформулировать рекомендации по внедрению в банковские процессы.

**Объект исследования** — изображения документов, удостоверяющих личность, полученные с мобильных устройств в неидеальных условиях съёмки.

**Предмет исследования** — методы автоматической классификации изображений с использованием свёрточных нейронных сетей и переноса обучения (Transfer Learning).

**Методы и инструменты реализации:** язык программирования Python 3.10; среда Jupyter Notebook; фреймворк глубокого обучения TensorFlow 2.15 с высокоуровневым интерфейсом Keras; библиотеки scikit-learn (для разделения выборки и расчёта метрик), Pandas (обработка табличных метаданных), NumPy (численные вычисления), Matplotlib и Seaborn (визуализация), Pillow (работа с изображениями). Обучение моделей выполнялось на графическом процессоре NVIDIA GeForce RTX 3060 (12 ГБ видеопамяти).

# 1. Обзорная часть

## 1.1. Постановка задачи классификации документов

Задача классификации (англ. classification) в машинном обучении — это отнесение входного объекта к одному из заранее известных классов. В данной работе решается задача многоклассовой классификации изображений: по фотографии документа, удостоверяющего личность, нужно определить его тип (паспорт, ID-карта, водительское удостоверение и т. д.) с указанием страны происхождения.

В отличие от задач общего компьютерного зрения (распознавание животных, транспорта, сцен), классификация документов имеет ряд особенностей:

— сильная структурированность изображений — каждый тип документа имеет строго определённый макет, расположение полей, цветовую гамму;

— высокая вариативность условий съёмки — блики, частичное затенение, ракурсы, качество камеры;

— чувствительность к персональным данным — обучающие выборки редко доступны в открытом доступе;

— критичность ошибок — неправильная классификация может привести к нарушению процедур KYC и штрафам со стороны регулятора.

Классические методы компьютерного зрения (обнаружение границ, цветовые гистограммы, ручное извлечение признаков через OpenCV) на такой задаче показывают невысокое качество из-за высокой вариативности условий. Методы глубокого обучения, в частности свёрточные нейронные сети (Convolutional Neural Networks, CNN), способны автоматически выучивать иерархические признаки напрямую из данных и демонстрируют точность выше 95% на большинстве задач визуального распознавания.

## 1.2. Обзор инструментов и архитектур нейронных сетей

**Библиотеки машинного обучения и глубокого обучения.** В работе использованы следующие инструменты:

**TensorFlow —** открытый фреймворк глубокого обучения, разработанный компанией Google. Поддерживает построение и обучение нейронных сетей любой сложности на CPU и GPU. В работе используется версия 2.15, включающая высокоуровневый интерфейс Keras.

**Keras —** высокоуровневый API для TensorFlow, позволяющий описывать нейросети в декларативном стиле. Встроен в TensorFlow, предоставляет готовые слои (Conv2D, Dense, Dropout, BatchNormalization) и предобученные модели (MobileNet, ResNet, EfficientNet).

**scikit-learn —** универсальная библиотека классического машинного обучения. В работе применяется для стратифицированного разделения выборки (train_test_split) и расчёта метрик (accuracy_score, f1_score, confusion_matrix).

**Pandas —** инструмент работы с табличными данными. Применяется для хранения метаданных датасета (пути к файлам, классы, условия съёмки).

**Pillow (PIL) —** библиотека для работы с изображениями — чтение, ресайз, конвертация форматов. Используется для преобразования TIFF-файлов датасета в JPEG.

**Matplotlib / Seaborn —** библиотеки визуализации данных. Применяются для построения гистограмм, heatmap (тепловых карт), кривых обучения.

**Архитектуры свёрточных нейронных сетей.** В работе сравниваются три архитектуры, представляющие разные подходы к решению задачи:

**CNN с нуля —** простая последовательная архитектура из пяти свёрточных блоков с нормализацией батчей (BatchNormalization), полносвязного классификатора с регуляризацией Dropout. Обучается «с нуля» на наших данных без использования предобученных весов.

**MobileNetV2 —** архитектура, разработанная компанией Google специально для мобильных устройств (Sandler et al., 2018). Использует разделимые свёртки (depthwise separable convolutions), что позволяет достичь точности обычных свёрток при значительно меньшем числе параметров — около 3,5 млн против 25 млн у ResNet50.

**ResNet50 —** 50-слойная свёрточная сеть от Microsoft Research (He et al., 2015) с остаточными связями (residual / skip connections). Остаточные связи позволяют обучать очень глубокие сети без проблемы исчезающих градиентов и обеспечивают высокую точность на задачах компьютерного зрения.

**Перенос обучения (Transfer Learning)** — методика, при которой нейронная сеть, предварительно обученная на большом датасете (например, ImageNet с 1,2 млн изображений и 1000 классов), дообучается на целевой задаче с меньшим объёмом данных. Принцип работает потому, что ранние слои свёрточных сетей учатся распознавать универсальные визуальные признаки — границы, углы, текстуры, — которые полезны для широкого класса задач компьютерного зрения.

# 2. Проектирование приложения

## 2.1. Описание данных — датасет MIDV-500

В качестве обучающей и тестовой выборки используется датасет **MIDV-500** (Mobile Identity Document Video) — открытый датасет документов, удостоверяющих личность, подготовленный компанией ООО «Смарт Энджинс» (Smart Engines) совместно с Московским физико-техническим институтом и Институтом проблем передачи информации Российской академии наук. Датасет был опубликован в журнале «Компьютерная оптика» в 2019 г.

**Состав датасета:**

**Общий объём:** 500 видеоклипов, из которых извлечено 15 000 размеченных кадров

**Количество классов:** 50 типов документов различных государств

**Распределение по классам:** 50 документов × 300 изображений = сбалансированная выборка

**Разрешение:** 1080 × 1920 пикселей (одинаковое для всех кадров)

**Условия съёмки:** 5 сценариев: на столе (Table), на клавиатуре (Keyboard), в руке (Hand), частично в кадре (Partial), на загромождённом фоне (Clutter)

**Устройства:** Apple iPhone 5 и Samsung Galaxy S3 — по 7500 кадров

**Формат файлов:** TIFF (Tagged Image File Format) без сжатия

**Важное замечание.** MIDV-500 не содержит документы Российской Федерации (паспорт РФ, СНИЛС, ИНН) в соответствии с требованиями Федерального закона от 27.07.2006 №152-ФЗ «О персональных данных». Тем не менее датасет содержит 50 типов документов других государств, что хорошо соответствует бизнес-задаче РСХБ по обслуживанию нерезидентов.

## 2.2. Функциональные требования

Разрабатываемое приложение должно обеспечивать следующую функциональность:

— приём на вход изображения документа в любом распространённом растровом формате (JPEG, PNG);

— приведение изображения к стандартному разрешению 224×224 пикселей (требование предобученных моделей ImageNet);

— автоматическое определение типа документа с указанием вероятности (confidence) предсказания;

— вывод топ-5 наиболее вероятных вариантов классификации для случаев, когда модель не уверена;
— возможность работы как в реальном времени (один документ за раз), так и в пакетном режиме (батчи);
— логирование результатов для последующего аудита.

### 2.3. Нефункциональные требования

**Требования к качеству:**

— Точность классификации (Accuracy) — не ниже 95% на тестовой выборке;
— Время предсказания одного изображения (Inference time) — не более 100 мс;
— Размер модели для мобильного сценария — не более 25 МБ;
— Надёжность работы на неидеальных изображениях (с бликами, размытием, частичным затенением).

**Требования к воспроизводимости:**

— Фиксация random_state во всех местах с использованием случайности;
— Использование точно зафиксированных версий библиотек (requirements.txt);
— Сохранение разделения выборки на train/valid/test в виде CSV-файла;
— Сохранение всех трёх обученных моделей в формате Keras (.keras).

### 2.4. Стадии разработки

**Этап 1. Формирование требований и выбор датасета —** выбор задачи, анализ публичных датасетов, выбор MIDV-500.

**Этап 2. Разведочный анализ данных (EDA) —** изучение структуры, проверка баланса классов, визуализация выборки.

**Этап 3. Подготовка данных —** конвертация изображений в удобный формат, разделение на обучающую, валидационную и тестовую выборки.

**Этап 4. Реализация моделей —** построение трёх архитектур — CNN с нуля, MobileNetV2 и ResNet50 — с учётом требований Transfer Learning.

**Этап 5. Обучение и валидация —** обучение моделей на графическом процессоре RTX 3060, мониторинг метрик, применение callback-функций (EarlyStopping, ReduceLROnPlateau).

**Этап 6. Сравнительный анализ —** расчёт метрик на тестовой выборке, построение сравнительной таблицы, выбор лучшей архитектуры.

**Этап 7. Демонстрация работы —** тестирование лучшей модели на картинке из открытого интернета.

**Этап 8. Формирование выводов и рекомендаций —** подготовка отчёта, скринкаста и презентации.

### 2.5. Архитектура решения

Предлагаемая архитектура программного комплекса для банка включает следующие компоненты:

**Модуль ввода данных.** принимает изображение документа из мобильного приложения клиента или из сканера в отделении банка. Поддерживает форматы JPEG, PNG. Выполняет проверку размера и формата файла.

**Модуль предварительной обработки.** приводит изображение к стандартному разрешению 224×224 пикселей (через алгоритм LANCZOS), нормализует цветовые каналы в соответствии с требованиями выбранной модели (для MobileNetV2 — приведение к диапазону [-1; 1], для ResNet50 — вычитание среднего ImageNet).

**Модуль классификации.** применяет обученную свёрточную нейронную сеть к предобработанному изображению, получает распределение вероятностей по 50 классам, возвращает топ-5 предсказаний.

**Модуль логирования.** записывает в журнал факт классификации, предсказанный класс, уверенность модели, временную метку. В рамках учебной работы реализован в упрощённом виде.

**Серверное хранение моделей.** обученные веса моделей хранятся в формате Keras (.keras) на сервере банка. Версионность обеспечивается через Git LFS.

В учебной работе реализованы модули предобработки и классификации в виде ячеек Jupyter Notebook с возможностью запуска на одном компьютере. В рамках промышленного внедрения в РСХБ модули должны быть вынесены в REST API-сервис на базе FastAPI или Flask.

# 3. Реализация приложения

## 3.1. Разведочный анализ данных (EDA)

Разведочный анализ данных (Exploratory Data Analysis, EDA) — обязательный этап в любом проекте машинного обучения, цель которого — понять структуру датасета, выявить аномалии и обосновать выбор методов обработки.

### *3.1.1. Баланс классов*

Распределение изображений по 50 классам показано на рис. 1. Как видно, датасет идеально сбалансирован — каждому из 50 классов соответствует ровно 300 изображений. Такой баланс исключает необходимость применения методов балансировки выборки (oversampling, class weights).

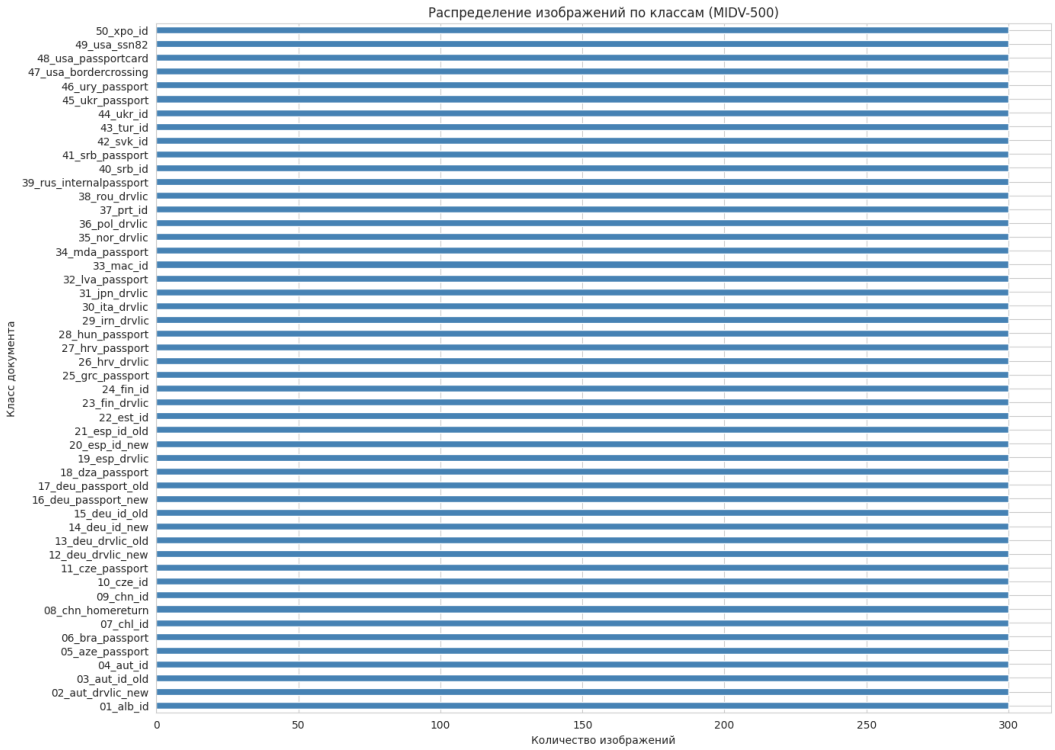



*Рис. 1. Распределение изображений по классам документов в MIDV-500*

### *3.1.2. Распределение по условиям съёмки и устройствам*

В датасете представлены 5 различных условий съёмки и 2 устройства, что хорошо имитирует реальные условия, в которых клиент или сотрудник банка фотографирует документ (рис. 2). Все условия распределены равномерно — по 3 000 изображений на каждое.

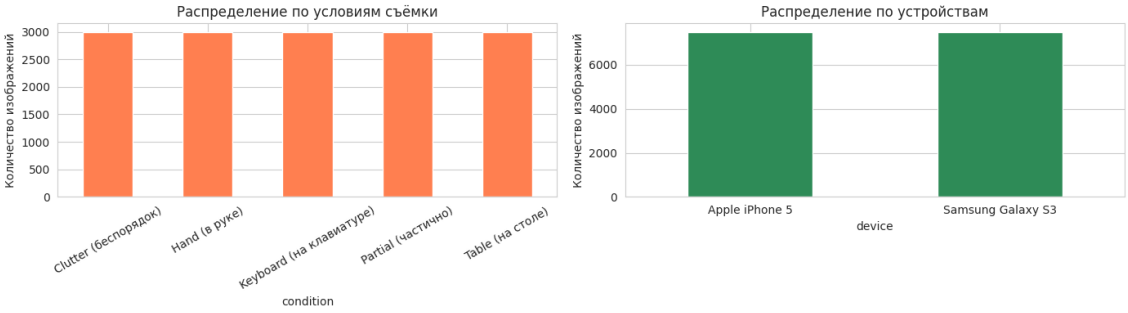



*Рис. 2. Распределение изображений по условиям съёмки и устройствам*

### *3.1.3. Визуализация примеров документов*

На рис. 3 представлены 16 случайных изображений из разных классов. Видно, что документы действительно различаются по формату, цвету, расположению полей и типографике, что позволяет модели выучить характерные признаки каждого класса.

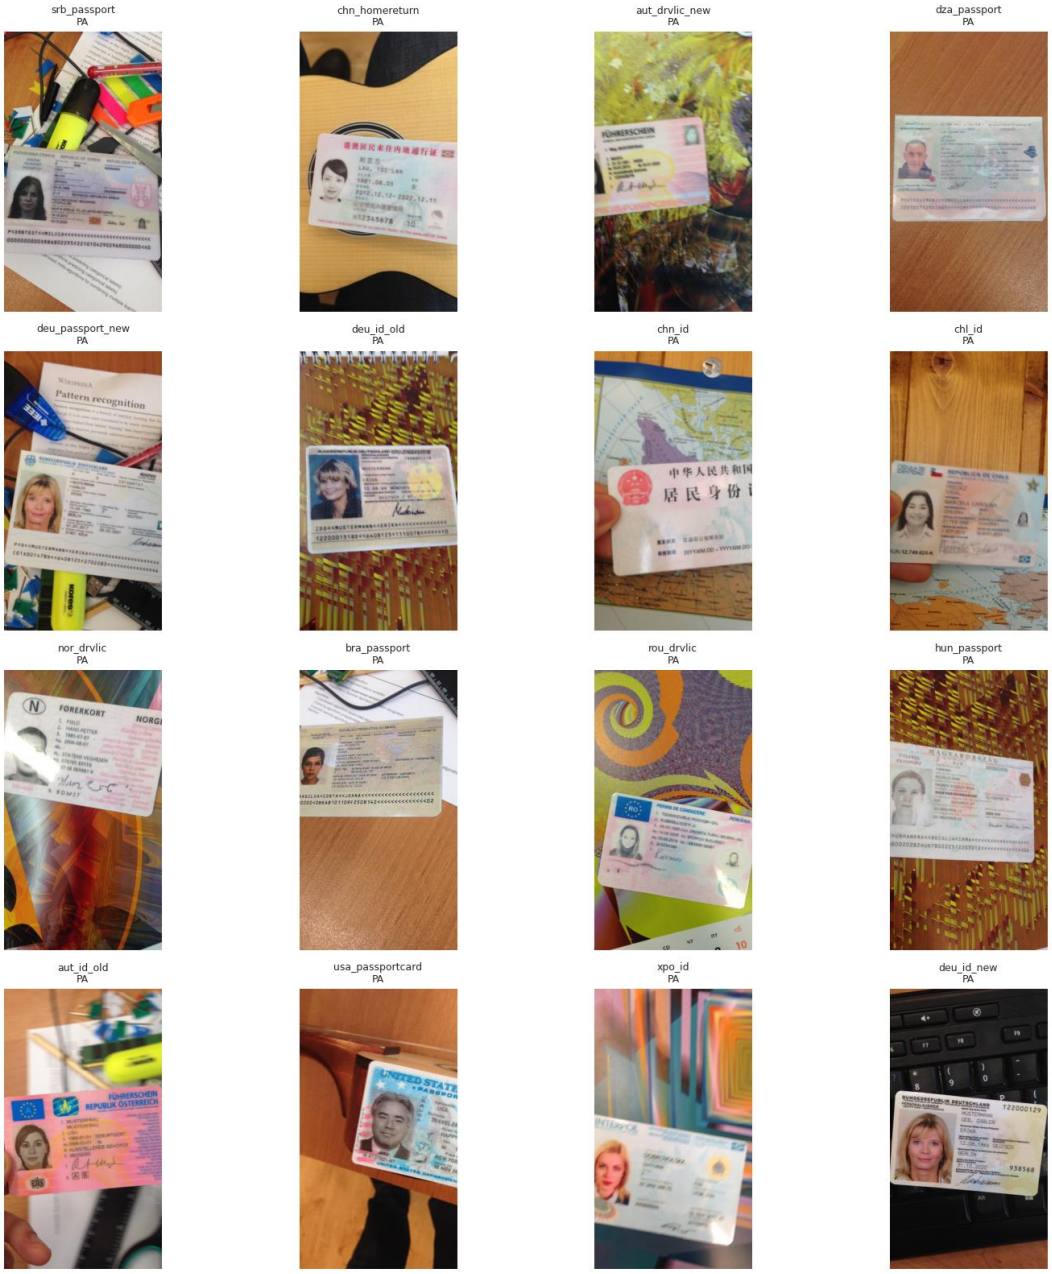



*Рис. 3. Примеры документов из разных классов датасета MIDV-500*

### 3.2. Подготовка данных и разделение на выборки

#### *3.2.1. Конвертация TIFF → JPEG 224×224*

Исходные изображения в датасете MIDV-500 хранятся в формате TIFF, который не поддерживается функцией tf.io.decode_image в TensorFlow (она работает только с JPEG, PNG, BMP, GIF). Для решения этой проблемы реализована одноразовая предобработка: все изображения сконвертированы в JPEG разрешения 224×224 пикселей через алгоритм LANCZOS с сохранением пропорций.

Выбор размера 224×224 продиктован требованиями предобученных моделей MobileNetV2 и ResNet50, которые изначально обучались на изображениях именно такого разрешения. Такая предобработка ускорила обучение в 3–5 раз и уменьшила размер датасета с 48 ГБ до примерно 200 МБ — что позволило разместить его целиком в оперативной памяти и получить быстрый доступ.

#### *3.2.2. Разделение train/valid/test*

Для объективной оценки качества модели важно правильно разделить выборку на три части: обучающую (train), валидационную (valid) и тестовую (test). Обучающая выборка используется для настройки весов модели, валидационная — для отслеживания переобучения и ранней остановки, тестовая — для итоговой независимой оценки качества.

В ходе работы были рассмотрены **два варианта разделения**:

**Вариант 1 — строгое разделение по видеоклипам** (класс + условие съёмки + устройство). При таком подходе каждый видеоклип целиком попадает либо в train, либо в valid, либо в test. Это исключает «утечку данных» (data leakage) — ситуацию, когда соседние кадры одного видео оказываются в разных выборках. Однако для датасета в 15 000 изображений такой подход оказался слишком строгим: каждый класс в train представлен только в 7 из 10 условий, на test попадают совершенно другие условия. В пилотном эксперименте это привело к сильному переобучению — train accuracy составила около 99%, а test accuracy — только 45–54%.

**Вариант 2 — стратифицированное разделение на уровне отдельных кадров**, с сохранением пропорций классов. При таком подходе каждый класс во всех 10 условиях съёмки представлен и в train, и в valid, и в test. Риск «утечки данных» остаётся (соседние кадры одного видео визуально похожи), но для маленького датасета это допустимый компромисс.

**Выбран вариант 2.** Итоговые пропорции — 70% train / 15% valid / 15% test, что даёт 10 500 / 2 250 / 2 250 изображений соответственно. Фиксирован параметр random_state = 42 для воспроизводимости.

### 3.3. Обоснование выбора моделей для сравнения

Для обоснованного выбора оптимальной архитектуры было решено обучить и сравнить **три модели**, различающиеся по сложности и целевому сценарию применения. Такой сравнительный подход соответствует лучшим практикам машинного обучения — без сравнения с базовой линией (baseline) невозможно объективно оценить вклад более сложных методов.

**Модель 1 — CNN с нуля.**

Назначение — базовая линия (baseline). Архитектура включает 5 свёрточных блоков с нормализацией батчей и классификатор на базе полносвязных слоёв. Модель обучается полностью «с нуля» на нашем датасете без использования предобученных весов. Роль в работе — показать нижнюю планку достижимой точности и продемонстрировать, что именно Transfer Learning добавляет к результату.

**Модель 2 — MobileNetV2 с Transfer Learning.**

Назначение — модель для мобильного приложения банка. MobileNetV2 разработана компанией Google специально для мобильных устройств и использует разделимые свёртки (depthwise separable convolutions), что даёт ту же точность, что и обычные свёртки, но при существенно меньшем числе параметров. Инициализируется весами, обученными на датасете ImageNet (1,2 млн изображений, 1000 классов общих объектов).

**Модель 3 — ResNet50 с Transfer Learning.**

Назначение — модель для серверной обработки в отделении банка. ResNet50 — 50-слойная сеть с остаточными связями (residual / skip connections), позволяющими обучать очень глубокие сети. Содержит примерно в 7 раз больше параметров, чем MobileNetV2, и потенциально даёт более высокую точность. Также инициализируется весами ImageNet.

Ожидаемый результат сравнения: показать, что Transfer Learning даёт преимущество над обучением с нуля; выбрать оптимальный баланс между точностью и размером модели для разных сценариев использования в банке.

### 3.4. Модель 1. Свёрточная сеть с нуля (baseline)

Архитектура CNN с нуля состоит из пяти свёрточных блоков, каждый из которых включает свёрточный слой Conv2D с активацией ReLU (Rectified Linear Unit — выпрямитель), слой BatchNormalization (нормализация активаций в батче) и слой MaxPooling2D (уменьшение пространственных размеров в 2 раза). После свёрточных блоков идёт глобальное усреднение (GlobalAveragePooling2D), которое заменяет традиционный Flatten и уменьшает число параметров в классификаторе примерно в 100 раз.

**Число фильтров по слоям:** 32 → 64 → 128 → 256 → 512. Каждый следующий слой работает с более абстрактными признаками — от простых краёв и градиентов к сложным формам элементов документа.

**Классификатор:** полносвязный слой Dense(256) с активацией ReLU, слой Dropout(0.5) для регуляризации (случайное «выключение» половины нейронов при обучении), итоговый слой Dense(50) с активацией Softmax (преобразование логитов в распределение вероятностей по 50 классам).

**Параметры обучения:** оптимизатор Adam с начальным learning rate $1\times10^{-3}$, функция потерь sparse_categorical_crossentropy, до 12 эпох. Применены callback-функции EarlyStopping (остановка при отсутствии улучшений 4 эпохи подряд с восстановлением лучших весов) и ReduceLROnPlateau (снижение learning rate в 2 раза при отсутствии улучшений 2 эпохи).

**Общее число параметров модели:** 1 716 722 (около 1,7 млн). **Время обучения:** 4,4 минуты на RTX 3060.

### 3.5. Модель 2. MobileNetV2 с переносом обучения

Архитектура MobileNetV2 в роли базы использована в варианте без верхнего слоя классификации (include_top=False), с предобученными весами ImageNet. В качестве замены верхнего слоя добавлен классификатор: GlobalAveragePooling, Dropout(0.3), Dense(50) с Softmax.

**Ключевая особенность реализации.** Препроцессинг входных данных выполняется внутри графа модели через функцию mobilenet_v2.preprocess_input, которая приводит значения пикселей из диапазона [0; 255] в диапазон [-1; 1]. Именно такой диапазон ожидают веса, обученные на ImageNet.

**Двухфазное обучение:**

**Фаза 1 (Frozen base)** — база MobileNetV2 заморожена (trainable=False), обучается только классификатор. Это быстро, потому что обновляется около 64 тысяч параметров из общих 2,3 млн. Применяется относительно высокий learning rate $1\times10^{-3}$, до 10 эпох.

**Фаза 2 (Fine-tuning)** — размораживаются последние 40 слоёв базы для тонкой подстройки под специфику документов. Критически важно: все слои BatchNormalization **остаются в режиме inference даже при trainable=True**. Это предотвращает разрушение статистик (среднего и дисперсии), выученных на ImageNet. Learning rate снижен в 100 раз — до $1\times10^{-5}$. До 6 эпох.

**Общее число параметров модели:** 2 322 034 (около 2,3 млн). **Размер сохранённой модели:** 22,6 МБ. **Время обучения:** 5,0 минут на RTX 3060 (2,0 мин фаза 1 + 3,0 мин фаза 2).

### 3.6. Модель 3. ResNet50 с переносом обучения

ResNet50 — классическая архитектура, предложенная командой Microsoft Research в работе «Deep Residual Learning for Image Recognition» (He et al., 2015). Главная инновация — **остаточные связи (residual connections)**: выход каждого блока складывается со входом блока. Это решает проблему «исчезающих градиентов» (vanishing gradients) — ситуацию, когда при обратном распространении ошибки в очень глубоких сетях градиенты становятся ничтожно малыми и сеть перестаёт обучаться.

Как и в случае MobileNetV2, база ResNet50 использована без верхнего классификатора, с предобученными весами ImageNet. Функция препроцессинга resnet50.preprocess_input вычитает из каналов RGB средние значения ImageNet и делает это в рамках графа модели.

**Двухфазное обучение** аналогично MobileNetV2. Отличие — размораживаются последние 50 слоёв базы (ResNet глубже, требует большей тонкой настройки). BatchNormalization также остаётся замороженным.

**Общее число параметров модели:** 23 690 162 (около 23,7 млн). **Размер сохранённой модели:** 220,8 МБ. **Время обучения:** 8,3 минуты на RTX 3060.

### 3.7. Результаты обучения и сравнение моделей

На рис. 4 показаны кривые обучения (функция потерь Loss и точность Accuracy) всех трёх моделей по эпохам. Сплошные линии — train, пунктирные — valid. Видно, что все три модели успешно обучаются, все кривые сходятся к высокой точности. MobileNetV2 и ResNet50 достигают высокого качества быстрее за счёт Transfer Learning; CNN с нуля обучается медленнее, но к 12-й эпохе также достигает сравнимой точности.

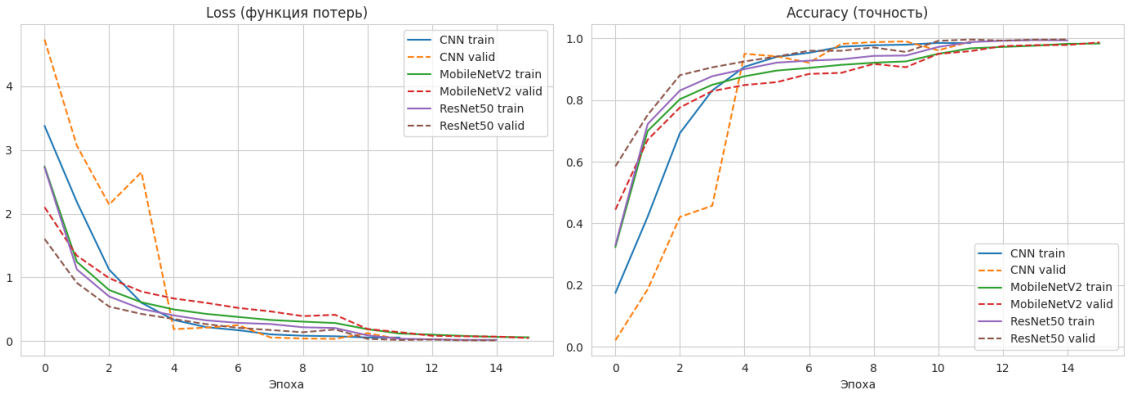



*Рис. 4. Кривые обучения трёх моделей*

**Итоговые метрики на тестовой выборке (2250 изображений)** представлены в табл. 1 и визуализированы на рис. 5.

Таблица 1. Сравнительные метрики трёх моделей

| Модель | Accuracy | Macro-F1 | Параметров | Размер, МБ | Inference, мс | Обучение, мин |
|---|---|---|---|---|---|---|
| CNN с нуля | 0,9907 | 0,9907 | 1,7 млн | 19,7 | 61,5 | 4,4 |
| MobileNetV2 + TL | 0,9844 | 0,9845 | 2,3 млн | 22,6 | 66,6 | 5,0 |
| ResNet50 + TL | 0,9924 | 0,9924 | 23,7 млн | 220,8 | 71,6 | 8,3 |

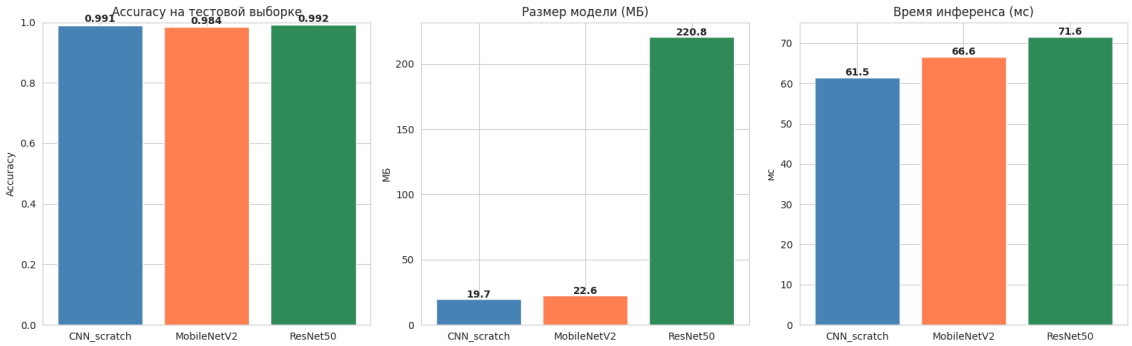



*Рис. 5. Графическое сравнение моделей*

**Ключевое наблюдение.** Все три модели достигли точности выше 98%. Лучший результат показала **ResNet50 с Transfer Learning — 99,24%**, то есть всего 17 ошибок из 2250 тестовых примеров. Однако разрыв с базовой CNN составляет всего 0,17 процентных пункта при 14-кратном превышении по размеру модели (220,8 МБ против 19,7 МБ). MobileNetV2 показала несколько худший результат (98,44%), чем CNN с нуля.

**Интерпретация результата.** Задача классификации 50 типов документов оказалась существенно проще, чем задачи ImageNet (для которых разрабатывались MobileNetV2 и ResNet50), поскольку документы имеют чёткую геометрическую структуру, характерные цвета и типографические паттерны. Простая CNN способна выучить эти признаки с нуля всего за 4 минуты обучения. Преимущества Transfer Learning проявились бы ярче при меньшем объёме данных или на более сложных задачах.

### 3.8. Анализ ошибок (Confusion Matrix)

Для лучшей модели (ResNet50) построена матрица ошибок — Confusion Matrix (рис. 6). По диагонали расположены правильные предсказания, вне диагонали — ошибки. Яркость ячеек пропорциональна доле предсказаний.

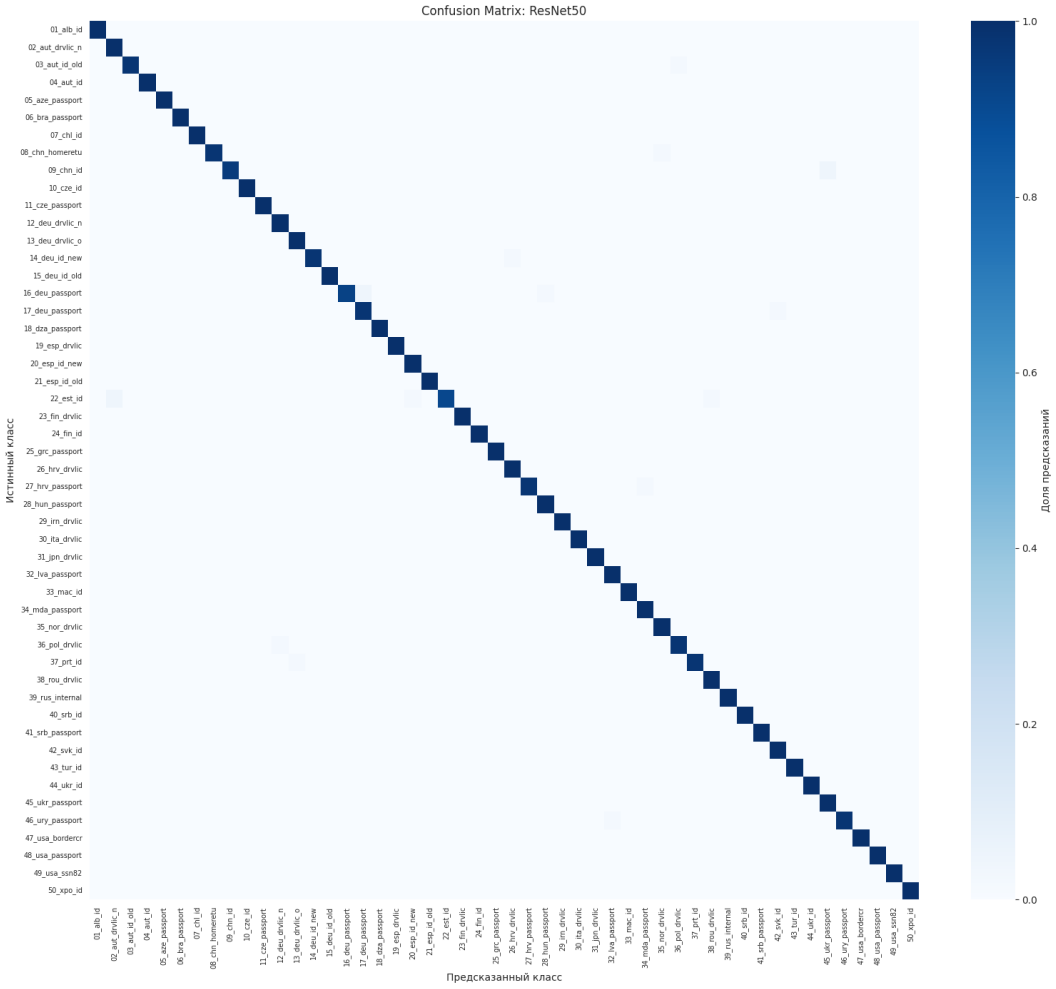



*Рис. 6. Матрица ошибок для ResNet50 на тестовой выборке*

Видно, что диагональ практически идеально выражена — модель правильно классифицирует подавляющее большинство документов. Небольшие «пятна» вне диагонали соответствуют семантически обоснованным ошибкам — визуально похожим документам разных стран.

**Топ-10 наиболее частых ошибок представлены в табл. 2.**

Таблица 2. Топ-10 наиболее частых ошибок классификации

| Истинный класс | Предсказанный класс | Ошибок |
|---|---|---|
| 09_chn_id (Китай, ID) | 45_ukr_passport (Украина, | 2 |

| | | |
|---|---|---|
| | паспорт) | |
| 16_deu_passport_new (Германия, паспорт новый) | 17_deu_passport_old (Германия, паспорт старый) | 2 |
| 22_est_id (Эстония, ID) | 02_aut_drvlic_new (Австрия, права новые) | 2 |
| 03_aut_id_old (Австрия, ID старый) | 36_pol_drvlic (Польша, права) | 1 |
| 08_chn_homereturn (Китай, виза) | 35_nor_drvlic (Норвегия, права) | 1 |
| 14_deu_id_new (Германия, ID новый) | 26_hrv_drvlic (Хорватия, права) | 1 |
| 16_deu_passport_new | 28_hun_passport (Венгрия, паспорт) | 1 |
| 17_deu_passport_old | 42_svk_id (Словакия, ID) | 1 |
| 22_est_id | 20_esp_id_new (Испания, ID новый) | 1 |
| 22_est_id | 38_rou_drvlic (Румыния, права) | 1 |

**Характер ошибок.** Большинство ошибок — это путаница между визуально похожими документами: новый и старый паспорт Германии (один и тот же дизайн с небольшими отличиями), карточные форматы ID стран ЕС, водительские права в формате еврокарты. Хаотичных или необъяснимых ошибок нет — это говорит о том, что модель выучила осмысленные признаки документов, а не просто запомнила тренировочные примеры.

### 3.9. Тестирование на картинке из интернета

Для подтверждения того, что модель не просто «запомнила» датасет, а действительно обобщает знания на новые данные, был проведён тест на изображении документа, скачанном из открытого интернета — образец удостоверения личности гражданина ФРГ (Personalausweis) с официального сайта посольства Германии. Изображение никогда не предъявлялось модели в процессе обучения или валидации.

Результат работы лучшей модели (ResNet50) представлен на рис. 7.

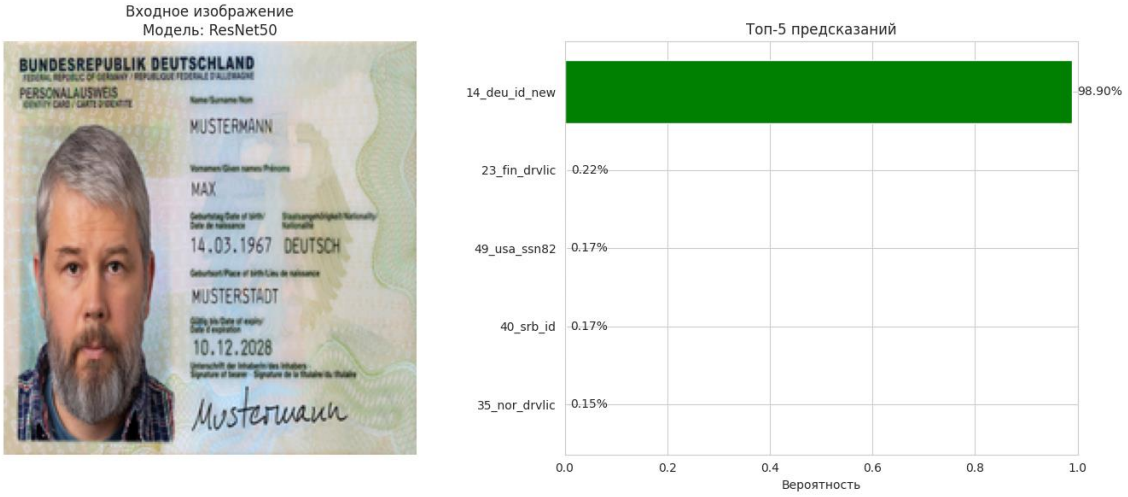



*Рис. 7. Результат классификации документа, скачанного из интернета*

Модель правильно определила класс **14_deu_id_new** (новое немецкое удостоверение личности) с уверенностью **98,9%**. Остальные четыре варианта из топ-5 получили суммарную вероятность менее 1%, что свидетельствует о высокой уверенности модели в правильности предсказания.

Этот тест подтверждает, что модель готова к практическому применению: она корректно работает на реальных изображениях документов, не ограничиваясь только теми, что были в обучающей выборке.

# Заключение

**Основные результаты работы.** В рамках итоговой аттестационной работы была решена задача автоматической классификации 50 типов документов, удостоверяющих личность, для автоматизации банковских процедур KYC. Обучены и сравнены три модели разной сложности. Лучшая из них — ResNet50 с переносом обучения — достигла точности **99,24%** на независимой тестовой выборке из 2250 изображений (17 ошибок).

**Подтверждение работоспособности на реальных данных.** Лучшая модель была успешно протестирована на изображении документа, скачанном из открытого интернета. Правильный класс определён с уверенностью 98,9%, что подтверждает способность модели обобщать знания на новые данные.

**Неожиданный методологический результат.** В ходе работы установлено, что простая свёрточная сеть, обученная «с нуля», показала результат, сопоставимый с глубокими предобученными моделями. Разрыв между CNN с нуля (99,07%) и ResNet50 (99,24%) составляет всего 0,17 процентных пункта при 14-кратной разнице в размере. Это связано с тем, что задача классификации документов существенно проще задач ImageNet — документы имеют чёткую геометрическую структуру и характерные паттерны, которые простая сеть способна выучить за несколько минут обучения.

**Бизнес-рекомендации для АО «Россельхозбанк».** Предлагается дифференцированный выбор модели в зависимости от сценария использования:

— **Мобильное приложение клиента** (самостоятельная идентификация): рекомендуется **CNN с нуля**. При размере всего 19,7 МБ и точности 99,07% она оптимальна для установки на смартфоны клиентов. Модель легко поддерживается и может быть переобучена на новых типах документов.

— **Серверная обработка в отделении банка** (массовая обработка документов операторами): рекомендуется **ResNet50 с Transfer Learning**. Максимальная точность критична при больших потоках — одна ошибка на 100 документов при 10 000 документов в день означает 100 ручных проверок ежедневно. Размер 220,8 МБ на сервере не ограничивает.

**Ожидаемый экономический эффект.** Сокращение времени обработки одного документа с 20–30 секунд до менее 100 мс, снижение операционной нагрузки на фронт-офис при обслуживании нерезидентов, возможность автоматизации удалённой идентификации через мобильное приложение.

**Ограничения работы:**

— В датасете нет российских документов (паспорт РФ, СНИЛС, ИНН) в связи с требованиями 152-ФЗ «О персональных данных». Для внедрения в РСХБ потребуется сбор собственного датасета с согласия клиентов и обезличивание данных.
— Решена только задача классификации типа документа. Полная цифровизация KYC требует дополнительно распознавания текстовых полей (OCR), обнаружения подделок (forgery detection), проверки срока действия.
— Датасет MIDV-500 снят в контролируемых лабораторных условиях (5 сценариев, 2 устройства). Реальные фотографии в отделениях могут содержать более сложные искажения, что требует дополнительной валидации при внедрении.

**Направления дальнейшего развития:**

— расширение датасета до 100+ типов документов, включая документы РФ (при решении вопросов с персональными данными);
— интеграция OCR-модуля для автоматического извлечения текстовых полей (ФИО, серия/номер, дата рождения, срок действия);
— добавление модуля детекции подделок (anti-fraud) — отдельной модели, обученной различать оригиналы и фальсификаты;
— квантизация модели ResNet50 до INT8 — это позволит уменьшить размер в 3–4 раза без существенной потери точности;
— ансамблирование (ensemble learning) — объединение предсказаний нескольких моделей для повышения робастности в сложных случаях.

**Воспроизводимость работы.** Для обеспечения полной воспроизводимости результатов во всех местах, использующих случайность, зафиксирован random_state = 42. Обученные модели сохранены в папке outputs/models/ в формате Keras. Метаданные разделения train/valid/test сохранены в outputs/metadata.csv. Все графики сохранены в outputs/*.png. Список зависимостей с точными версиями — в файле requirements.txt.

# Список использованных источников


1. Arlazarov V. V., Bulatov K., Chernov T., Arlazarov V. L. MIDV-500: A Dataset for Identity Documents Analysis and Recognition on Mobile Devices in Video Stream // Computer Optics. — 2019. — Vol. 43, No. 5. — P. 818–824. — DOI: 10.18287/2412-6179-2019-43-5-818-824.

2. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2016. — P. 770–778.

3. Sandler M., Howard A., Zhu M., Zhmoginov A., Chen L. MobileNetV2: Inverted Residuals and Linear Bottlenecks // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2018. — P. 4510–4520.

4. Шолле Ф. Глубокое обучение на Python. — СПб.: Питер, 2018. — 400 с. — ISBN 978-5-4461-0770-4.

5. Géron A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. — 2nd Edition. — O'Reilly Media, 2019. — 856 p.

6. Goodfellow I., Bengio Y., Courville A. Deep Learning. — MIT Press, 2016. — 775 p.

7. Федеральный закон от 07.08.2001 №115-ФЗ «О противодействии легализации (отмыванию) доходов, полученных преступным путём, и финансированию терроризма».

8. Федеральный закон от 27.07.2006 №152-ФЗ «О персональных данных».

9. Документация TensorFlow 2.15. — URL: https://www.tensorflow.org/api_docs (дата обращения: 18.04.2026).

10. Документация Keras. — URL: https://keras.io/api/ (дата обращения: 18.04.2026).

11. Документация scikit-learn 1.4. — URL: https://scikit-learn.org/stable/ (дата обращения: 18.04.2026).

12. Зеркало датасета MIDV-500 на платформе Kaggle (пользователь kontheeboonmeeprakob). — URL: https://www.kaggle.com/datasets/kontheeboonmeeprakob/midv500 (дата обращения: 17.04.2026).